
Informe técnico del framework

The NewsBreakers

Observatorio de desinformación zoonosanitaria

Arquitectura, método y criterios de un sistema local
de vigilancia mediática sobre enfermedades pecuarias.

Índice

1. Objeto y alcance	2
2. De dónde sale: el raspado como punto de partida	3
3. Para qué sirve en desinformación	3
4. Por qué esas tres enfermedades	4
5. Países, idiomas y por qué	5
6. Medios que se abordan	6
7. Cómo está estructurado el framework	6
8. Parámetros que gobiernan el ciclo	8
9. La red neuronal de visión	9
10. Sala, mapa, gráficas y grafo	10
11. Por qué se hizo así (y no de otra manera)	11
12. Límites que el propio sistema enseña	12
13. Cierre	12
14. Referencias	13
A. Último ciclo de minería	15
A.1. Por qué 15 y no 118	16
A.2. Errores de fuente observados	16
B. Métricas de la CNN	16
B.1. Métricas que harían defendible el modelo	18
C. Catálogo de fuentes	18
C.1. Diseño del catálogo	19
C.2. Muestra nominada (sala y ciclos)	19
C.3. Cómo completar las 118 filas	19
D. Por qué 26 en Mac y cómo igualar ~160	20
D.1. Paso concreto (igualar 160)	20
D.2. Seguir sumando (RSS y GDELT)	21
D.3. Lo que dejó minar-ya 8/8 (11 sep 2026)	21
D.4. Plan B y matices	21

Índice de tablas

1.	Qué hace —y qué no hace— el observatorio frente a un ítem.	4
2.	Criterios de inclusión de las tres enfermedades del núcleo.	4
3.	Política lingüística del observatorio.	6
4.	Tipos de medio en el catálogo y modo de acceso.	6
5.	Directorios que importan al operador (no es un inventario de todo el árbol).	7
6.	Parámetros operativos y por qué están donde están.	8
7.	Clases del clasificador <code>vision_cnn_v1</code>	9
8.	Corte operacional GET /stats	11
9.	Respuesta del ciclo <code>CYC-20260911T093819Z</code>	15
10.	Fuentes con HTTP 404 en el ciclo	16
11.	Soporte operacional de la CNN por clase	17
12.	Qué se puede citar de la CNN en este corte	17
13.	Criterios del directorio de fuentes	19
14.	Muestra nominada de fuentes	19
15.	26 en Mac frente a 160 tras faee421	20
16.	Recuentos tras los ocho ciclos, frente al snapshot.	21

1. Objeto y alcance

The NewsBreakers es un observatorio local —no un medio— que reúne, filtra y presenta noticias e imágenes sobre tres enfermedades pecuarias de alto impacto: el gusano barrenador del ganado (*Cochliomyia hominivorax*), la influenza aviar de alta patogenicidad y la peste porcina clásica. El operador trabaja en una sala de vigilancia: ve documentos, riesgo, alertas pendientes de revisión humana, un mapa, gráficas, un grafo de relaciones y un módulo de visión por computador.

El sistema no «decide la verdad». Clasifica relevancia, extrae afirmaciones, calcula un puntaje de riesgo y deja la última palabra a un analista. Eso es deliberado. En desinformación zoonosaria el coste de un falso positivo (alarma infundada) y de un falso negativo (brote minimizado) no es simétrico; por eso hay cola de revisión y umbrales explícitos, no un semáforo automático opaco.

Este informe describe cómo está hecho el framework, por qué se eligieron esas enfermedades, qué medios cubre, qué papel tiene la red neuronal de imágenes y con qué parámetros se gobierna el ciclo. Los recuentos corresponden a una corrida real del laboratorio (11 de septiembre de 2026; SQLite con MySQL opcional). No son una estadística nacional. La evidencia cuantitativa que un comité puede auditar está en los anexos A (último ciclo), B (métricas CNN), C (fuentes) y D (por qué 26 en Mac y cómo igualar ~160). Las fuentes mediáticas, institucionales y de software van en **Referencias**, en formato APA (7.^a ed.).

Cómo leer las cifras. Un ciclo que revisa 8 o 15 de 118 fuentes y no crea artículos nuevos no es un fallo oculto: es el diseño (*solo fuentes vencidas*, filtro de relevancia, deduplicado). Once imágenes de un solo género visual no autorizan a citar *accuracy* de la CNN. Donde no hubo `test_metrics.json`, este documento *no inventa* precisión.

2. De dónde sale: el raspado como punto de partida

El proyecto no nació como «plataforma de inteligencia». Nació como un problema de captura. La primera capa fue —y sigue siendo— conseguir texto e imagen de fuentes abiertas sin inventar páginas.

Esa fase tuvo tres lecciones que marcan el diseño actual:

1. **El HTML completo no escala en silencio.** Muchos sitios pecuarios y de agencias bloquean o redirigen el rastreo genérico. Por eso el acceso `scrape` quedó *diferido*: el ciclo lo anota, no lo ejecuta a ciegas.
2. **El RSS y las API sí se pueden programar.** Un canal Atom/RSS o un API documental (p. ej. GDELT) entrega ítems con título, fecha y URL. Es menos «profundo» que un *scraper* a medida, pero es repetible cada treinta minutos sin pelearse con cada plantilla.
3. **Sin deduplicado, el observatorio se inunda.** El mismo titular viaja por GDELT, un agregado científico y una redacción. El índice de duplicados (url y huella de texto) es tan importante como el propio fetch.

El ciclo de minería (`POST /cycle`) es esa herencia: primero sincroniza el catálogo de fuentes, luego pide solo las vencidas de método `rss` o `api`, registra errores (un 404 de *The Poultry Site* o de un feed de la OMS no tumba el ciclo), aplica deduplicado y recién entonces entra al análisis lingüístico y visual.



Figura 1: Orden real del ciclo. El raspado `scrape` no está en esta fila: se marca como diferido y no descarga HTML.

Ese orden explica una queja frecuente en laboratorio: pulsar «Ejecutar ciclo» no dispara 118 descargas. El catálogo puede tener 118 filas; el ciclo solo visita las fuentes *debidas* y, de ellas, solo RSS/API. El resto espera su `next_check`. No es un fallo de la sala: es la política de no golpear a los sitios.

3. Para qué sirve en desinformación

La desinformación zoonosanitaria no es un género aparte del rumor político: usa los mismos canales (titular, captura de pantalla, meme, documento con membrete). Cambia el daño. Un video de «pollo contaminado» o un PDF apócrifo de vacunación puede adelantar sacrificios, cerrar mercados o vaciar granjas de traspacio antes de que haya un comunicado oficial.

El observatorio interviene en tres momentos, ninguno de ellos sustituto de Senasica, USDA o la OIE/WOAH:

Captura

Deja constancia de *qué* se dijo, *dónde* y *cuándo*, con el texto o la imagen, no con un resumen oral de un analista.

Triaje

Separa lo irrelevante (turismo, finanzas, crimen común) de lo que nombra las tres enfermedades o sus vectores. Lo irrelevante se omite a propósito: no entra al conteo de artículos analizados.

Priorización humana

Un puntaje de riesgo y un veredicto (*insuficiente, revisión humana, etc.*) ordenan la cola. El analista confirma, descarta o etiqueta.

Tabla 1: Qué hace —y qué no hace— el observatorio frente a un ítem.

Paso	Lo que sí	Lo que no
Fetch RSS/API	Trae título, fecha, enlace y, si viene, cuerpo.	No entra al HTML de redacciones que exigen rastreador a medida.
Deduplicado	Evita contar dos veces el mismo documento.	No fusiona «versiones» periodísticas distintas.
Relevancia	Tira lo que no habla de las tres enfermedades.	No es un modelo de <i>fact-checking</i> general.
Afirmaciones	Parte el texto en claims y busca entidades.	No atribuye autoría legal ni intención.
Riesgo / alerta	Ordena la cola si se cruza el umbral.	No publica un boletín automático.
CNN de imagen	Sugiere el <i>tipo</i> de visual (meme, acta, foto...).	No certifica si una foto está «photoshoppeada».
Revisión humana	Cierra el ciclo con etiqueta de analista.	No sustituye al dictamen sanitario oficial.

En prevención, el valor no es «detectar fake news» como eslogan. Es acortar el tiempo entre *aparece en un feed* y *un humano lo ve con contexto*: fuente, fecha, enfermedad, riesgo, imagen y documentos vecinos en el grafo.

4. Por qué esas tres enfermedades

No hay un tablero de «todas las zoonosis». Hay tres nombres a propósito. Ampliar el diccionario sin analistas ni fuentes es producir ruido.

Tabla 2: Criterios de inclusión de las tres enfermedades del núcleo.

Enfermedad	Por qué entra	Qué se vigila en medios
Gusano barrenador (<i>C. hominivorax</i>)	Reemergencia en el corredor México–Centroamérica; impacto en ganado y fauna; alto potencial de pánico en caza y traspatio.	Avisos a cazadores, «bichos en heridas», rumores de liberación o de fracaso de la mosca estéril.
Influenza aviar (alta patogenicidad)	Circulación global en aves de corral y silvestres; lenguaje técnico (HPAI) que se deforma en redes.	Granjas, comederos de patio, sacrificio, «gripe del pollo» como pánico alimentario.
Peste porcina clásica	Enfermedad de declaración obligatoria; confusión frecuente con peste porcina africana en titulares.	Cierres de granja, contrabando de cerdos, vacunas «ocultas» o «experimentales».

Se eligieron porque cumplen cuatro condiciones a la vez:

- hay **vocabulario estable** en español y en inglés (nombres comunes, siglas, huéspedes);
- el **daño mediático** es concreto (mercado, sacrificio, caza, traspas), no solo reputacional;
- existen **fuentes abiertas** que las cubren con cierta regularidad (prensa pecuaria, ciencia, cables, GDELT);
- un analista mexicano puede contrastar contra comunicados de autoridad sin montar un CDC privado.

Lo que queda fuera —COVID humano, dengue, rumores de vacunas infantiles— no es porque «no importe». Es porque diluiría el filtro de relevancia y la cola humana. El framework admite más claves; el observatorio, en esta versión, no las enciende.

5. Países, idiomas y por qué

El centro operativo es **México**: la sala está en español, hay redacción mexicana en el corpus (p. ej. *El País México*) y las tres enfermedades importan al servicio sanitario nacional. El mapa de la interfaz no es un atlas epidemiológico: es un tablero de *dónde se dice* que ocurre algo, según el texto capturado, no según un GIS oficial.

El inglés entra por las fuentes, no por snobismo. La literatura de influenza aviar, los cables y GDELT llegan en inglés. Un operador que solo viera español perdería el aviso a cazadores de *screwworm* o el paper de *Science News* sobre comederos de patio. Por eso hay un conmutador «Traducir al español»: es una capa de lectura, no el idioma de almacenamiento. El artículo se guarda como llegó; la traducción se cachea.



Figura 2: Geografía de trabajo. México es el puesto de mando; el inglés es insumo. Las fronteras del dibujo son esquemáticas.

Tabla 3: Política lingüística del observatorio.

Capa	Idioma	Motivo
Almacenamiento	El del origen (es, en, mezclas).	No se reescribe la prueba. Un claim se cita como salió.
Interfaz	Español.	El analista opera en México.
Traducción opcional	Inglés → español, bajo demanda.	Leer ciencia y cables sin cambiar el registro de la base.
Filtro de relevancia	Léxico bilingüe de las tres enfermedades.	«screwworm» y «gusano barrenador» son el mismo objeto.

6. Medios que se abordan

El catálogo mezcla tipos que no se comportan igual. Tratar a un meme como si fuera un RSS de *Science News* es el error que el diseño intenta no cometer.

Tabla 4: Tipos de medio en el catálogo y modo de acceso.

Tipo	Acceso previsto	Papel en desinformación
Agregadores documentales (GDELT DOC 2.0)	API / feed.	Mucho volumen, poco cuerpo; sirven de radar, no de acta.
Prensa científica y pecuaria	RSS.	Vocabulario técnico; a veces el rumor nace de un titular correcto mal leído.
Prensa general (p. ej. <i>El País</i>)	RSS.	Encuadre nacional; llega al público no especialista.
Organismos (OMS y análogos)	RSS (si el URL vive).	Ancla de referencia; cuando el feed muere (404), el ciclo lo registra y sigue.
YouTube / redes	Campos en catálogo; ingestión aún desigual.	Donde más circula la imagen recortada y el audio.
Documento e imagen adjunta	Tras el ítem, cola de visión.	Membrete falsos, pantallazos, fotos de animales.

El método `scrape` existe en el catálogo porque al principio se quiso «entrar a la nota». En producción se aplazó: mantener selectores CSS de decenas de redacciones es un segundo producto. Hasta que no esté, esas fuentes no inflan el contador de artículos; aparecen como *diferidas*. Es más honesto que un raspado a medias.

Las fichas de las fuentes consultadas —prensa, organismos, agregadores y los RSS que devolvieron 404— están en **Referencias**, redactadas según la 7.^a edición del *Publication Manual* de la American Psychological Association (American Psychological Association, 2020). Un 404 no excluye la entrada: el canal se consultó; el endpoint no sirvió.

7. Cómo está estructurado el framework

El repositorio es un monorepo local. No hay microservicios en la nube obligatorios. MySQL en Docker es almacén opcional; SQLite cubre el laboratorio. Esa decisión cabe en un portátil y evita que el observatorio dependa de una cuenta SAAS para abrir la sala.

Dos procesos tienen que estar vivos para ver la sala: el tablero en `127.0.0.1:5173` y el API en `127.0.0.1:8010`. Ollama y Docker son opcionales. Si se apaga el API, la página puede pintar el



Figura 3: Capas del framework. La sala nunca habla con la base: pasa por el API.

Tabla 5: Directorios que importan al operador (no es un inventario de todo el árbol).

Ruta	Función
ingestion/	Fetch, normalización, deduplicado.
pipeline/run.py	Orquesta un ciclo completo.
api/	Contrato HTTP de la sala, incluido /translate.
frontend/	Tablero (Vite 5).
ai_service/vision/	Entrenamiento y uso de la CNN.
database/	Store SQLite/MySQL, corpus, caché.
workers/	Colas de imagen e NLP.
mac/	Arranque y parada en macOS, en segundo plano.
models/cnn/	Pesos .pt, historial y métricas de prueba.

cascarón y mostrar «no se pudo conectar con el servidor»: no es un fallo de Safari, es el cerebro detenido. Los datos ya guardados no se borran al cerrar.

8. Parámetros que gobiernan el ciclo

No hay un único «score de fake». Hay varios números con oficio distinto. Confundirlos es el atajo que el código evita.

Tabla 6: Parámetros operativos y por qué están donde están.

Parámetro	Valor de laboratorio	Criterio
Umbral de alerta (TNB_ALERT_THRESHOLD)	55 (0–100)	Por debajo, el ítem existe pero no entra a la cola roja. 55 evita llenar <i>Revisión</i> con ruido.
Máximo de fuentes RSS/API por ciclo	40 (antes 8)	El 8 protegía al portátil y a los sitios. El 40 solo tiene efecto sobre fuentes <i>vencidas</i> .
Fuentes <i>scrape</i> por ciclo	8, diferidas	Se anotan; no se descarga el HTML.
Intervalo de minería	1800 s	Media hora: suficiente para un radar, insuficiente para un DDOS a un feed.
Reintento / <i>backoff</i>	según fallos seguidos	Un 404 no se martillea cada minuto.
Presupuesto LLM en el ciclo	3 si hay Ollama; 0 si no	El ciclo no depende de un modelo de lenguaje. Sin él, hay claims extractivos y sin explicación generativa.
Traducción: tope de textos / caracteres	40 textos, 4000 caracteres	La sala traduce títulos y extractos, no el periódico entero.
Paginación de sala	12 tarjetas	Cabe en una pantalla; el resto es página 2 y 3.

El **riesgo** del recuadro (p.ej. 20, 38, 62) no es un porcentaje de «mentira». Combina, en el motor de riesgo, severidad del claim, fiabilidad percibida de la fuente y señales de narrativa (*vacunas, ocultamiento, origen artificial, brote*). Un 62 en una nota de laboratorio sobre armas biológicas no afirma que el hecho sea falso: afirma que merece ojos humanos antes que el resto.

Los **veredictos** de tarjeta (*insuficiente, revisión humana*) son estados de evidencias, no sentencias. *Insuficiente* quiere decir: no hay aún base para un juicio fuerte. Por eso conviven con un riesgo bajo o medio.




Figura 4: Riesgo mostrado en cuatro tarjetas de una misma sala (laboratorio, septiembre de 2026). No es una serie temporal: es una fotografía del tablero.

9. La red neuronal de visión

La CNN no lee el artículo. Mira la *imagen* asociada y propone una clase de *género visual*. Eso importa en desinformación porque el mismo rumor cambia de peso si viaja como acta con membrete, como pantallazo de un noticiero, como meme o como fotografía de un animal herido.

Tabla 7: Clases del clasificador `vision_cnn_v1`.

Clase	Para qué está
OFFICIAL_DOCUMENT	Membrete, oficios, PDF capturados. Alto riesgo si son falsos; alto valor si son auténticos.
NEWS_SCREENSHOT	Televisión o portal recortado. Suele circular fuera de contexto.
SOCIAL_MEDIA	UI de red social. Marca procedencia informal.
MEME	Texto incrustado, humor o agravio. Rara vez es evidencia; sí es vector.
INFOGRAPHIC	Cifras y mapas caseros. Fáciles de fabricar.
ANIMAL_HEALTH_CONTENT	Material específicamente pecuario o clínico.
PHOTOGRAPH	Foto «cruda» de animal, granja o lesión.
POTENTIALLY_MANIPULATED	Señal débil de edición. No es peritaje forense.

En una corrida de laboratorio el conjunto de entrenamiento efectivo quedó muy sesgado: once muestras en `OFFICIAL_DOCUMENT` y cero en el resto de clases (anexo B). Eso se declara aquí porque un modelo con once fotos de un solo género **no** es un detector de manipulación listo para producción. Es un prototipo: sirve para cablear el entrenamiento (`python-mai_service.vision.train_cnn`), guardar `vision_cnn_v1.pt` y mostrar la pestaña CNN. Hace falta corpus etiquetado —pantallazos, memes, fotos de campo— antes de fiarse del recuadro. El anexo B fija qué se puede afirmar hoy y qué métricas harían falta para defender el modelo.



Figura 5: Composición del dataset de visión en laboratorio. El sesgo es el dato, no un accidente que se oculte.




Figura 6: La red propone; no cierra el expediente.

Entrenar de nuevo es explícito y local. No hay «la IA se actualiza sola». Si no hay diversidad de clases, reentrenar solo memoriza membertes.

10. Sala, mapa, gráficas y grafo

La interfaz no es un *dashboard* de marketing. Cada pestaña lee el mismo API y enseña un corte del mismo Store.

Sala

Tarjetas con miniatura, veredicto, riesgo, extracto y fuente. Paginada. Filtros por enfermedad, país, veredicto, fuente y fechas.

Revisión

Cola HTTP: `alertas pending_review`. Aquí se gasta el tiempo del analista, no en el RSS crudo.

Mapa

Geolocalización de menciones (`/geo`). Útil para ver si el barrenador «aparece» en notas de caza estadounidenses y el pánico, en redes mexicanas.

Gráficas

Series y recuentos (`/charts`): artículos, claims, riesgo, menciones por enfermedad.

Grafo

Nodos artículo–claim–entidad–narrativa (`/graph`). Sirve para ver si cinco notas distintas empujan la misma historia de «ocultamiento».

CNN

Estado del dataset visual y, cuando hay modelo, la clase sugerida.

Fuentes

Salud del catálogo: última captura, fallos seguidos, método, estado (*operativa, diferida, error*).




Figura 7: Esquema del grafo (no es un volcado de la base). Dos notas pueden no compartir redacción y sí compartir narrativa.

El corte del 11 de septiembre de 2026, con MySQL opcional conectado y SQLite de respaldo, es el de la tabla 8: 26 documentos *antes* de aterrizar el snapshot. Ese número no es un tope del código. El corpus de Windows (~160, con Excel y YouTube) está en el repo privado desde el commit faee421; un `git pull` y reiniciar la sala lo igualan (anexo D). El ciclo CYC-20260911T093819Z (anexo A) sigue siendo la prueba de que un fetch RSS, aunque traiga 57 ítems, puede dejar **cero** artículos nuevos si solo reconsulta URL ya vistas.




Figura 8: Menciones por enfermedad en la misma corrida de laboratorio (26 documentos). La influenza aviar domina el inglés científico; la peste porcina clásica aún no tiene masa en ese corte.

Tabla 8: Corte operacional (`GET /stats` y chips de sala) el 11 de septiembre de 2026 a las 09:38 UTC, antes de aterrizar el snapshot `faee421`. Tras `git pull` el recuento esperado es ~160.

Indicador	Valor	Lectura
Documentos en sala (antes del snapshot)	26	Corte 09:38 UTC; no es un tope.
Tras <code>git pull</code> $\geq$ <code>faee421</code> (esperado)	~160	Snapshot Windows (Excel, YouTube, RSS).
YouTube / redes en el snapshot	~37	No crecen sin claves de API.
Afirmaciones (claims)	90	Extraídas; no verificadas aún.
Alertas pendientes	7	Cola HTML (<code>pending_review</code>).
Fuentes en catálogo	118	No son 118 descargas por ciclo.
Imágenes en visión	11	Todas <code>OFFICIAL_DOCUMENT</code> .
Menciones (chips de sala)	2 / 8 / 0	Barrenador / aviar / PPC.
Método de captura	≈100 % RSS	scrape diferido.

11. Por qué se hizo así (y no de otra manera)

Local primero

Un observatorio de rumores pecuarios no debería depender de que un proveedor nuble el índice. SQLite abre la sala en un Mac; MySQL entra cuando hay Docker. El API en 127.0.0.1 no es un capricho de desarrollo: es el perímetro.

RSS/API antes que *scrape* masivo

Mantener cincuenta extractores frágiles es un medio, no un observatorio. Se pospuso el HTML. Los 404 se auditan.

Relevancia estricta

Mejor 26 notas de las tres enfermedades que 400 de «salud» genérica. Tras `minar-ya` 8/8 eso se demostró al revés: 337 filas, 126 fuera de mandato y un cuerpo scrapeado que colaba reseñas. El gate nuevo exige la enfermedad *en el título*; el modelo local no admite.

Humano al final

El umbral 55 y la cola de revisión existen porque un modelo de 3 B traduciendo titulares no es un epidemiólogo, y una CNN de once membertes no es un perito.

Traducción como capa, no como verdad

Se cachea. No se pisa el original. Un modelo pequeño alucina («gusano cebolla» por *screw-worm*); por eso el conmutador es opcional y el inglés se conserva.

Visión aparte del texto

El rumor visual no se detecta con *bag-of-words*. La CNN es un clasificador de género, no un oráculo de autenticidad.

12. Límites que el propio sistema enseña

Conviene escribirlos con la misma letra que el resto, no en un anexo vergonzante.

- El catálogo de 118 fuentes no es 118 descargas por clic. Solo las vencidas de RSS/API entran al fetch.
- Feeds muertos (404) se cuentan como error de fuente, no como «cero desinformación».
- El filtro de relevancia tira ítems que un periodista igual querría ver. Es el precio de no ahogar la cola.
- Sin Ollama, el ciclo sigue; sin el API, la sala no.
- MySQL «atrasado» significa que el almacén opcional no está al día o Docker está cerrado. SQLite puede seguir sirviendo los 26 documentos.
- La CNN está subalimentada. Tratarla como detector de *deepfakes* sería una forma de desinformación interna.

13. Cierre

The NewsBreakers es un marco para no perder de vista tres enfermedades pecuarias en el ruido de los feeds. Empieza en el raspado disciplinado —qué se puede pedir sin romper sitios—, sigue en un API local y termina en una sala donde un humano ve riesgo, mapa, grafo y tipo de imagen. La prevención, aquí, no es un modelo que «apaga» rumores. Es llegar antes a la nota, con el original intacto, y decidir con los ojos abiertos.

Los anexos que siguen no son adorno: son el material con el que se puede defender el documento. Un ciclo con cero artículos nuevos, una CNN con una sola clase poblada y un catálogo de 118 fuentes del que solo maduran unas pocas por corrida son, juntos, la prueba de que el sistema está instrumentado —y de que todavía no es un oráculo.

Cómo citarse en borrador: *The NewsBreakers, Observatorio de desinformación zoonosanitaria: arquitectura, método y criterios*, informe técnico del framework, v. 1.5, México, septiembre de 2026. Los recuentos de laboratorio no deben citarse como incidencia epidemiológica. Las métricas de visión no deben citarse como exactitud generalizable.

14. Referencias

Lista de fuentes consultadas en formato de la 7.^a edición del *Publication Manual of the American Psychological Association*. Sangría francesa de 1,27 cm; títulos de obras en cursiva; s.f. cuando el canal no declara fecha de obra. Los feeds rss cambian con el tiempo: APA 7 pide fecha de recuperación. Fecha de consulta de los canales del ciclo CYC-20260911T093819Z: 11 de septiembre de 2026. Un HTTP 404 no retira la entrada; documenta que se intentó el acceso.

Cómo citar este informe

The NewsBreakers. (2026). *Observatorio de desinformación zoonosanitaria: arquitectura, método y criterios* (Informe técnico, v. 1.5) [Documento de trabajo].

Fuentes mediáticas e institucionales

Centro Europeo para la Prevención y el Control de las Enfermedades. (s.f.). ECDC RSS [Canal RSS]. Recuperado el 11 de septiembre de 2026 de <https://www.ecdc.europa.eu/en/rss.xml>

Ediciones El País. (s.f.). *El País* (edición México). <https://elpais.com>

Food & Agribusiness World. (s.f.). *Poultry* [Canal RSS]. Recuperado el 11 de septiembre de 2026 de <https://www.foodagribusiness.world/poultry/rss>

Leetaru, K. y Schrodtt, P. A. (2013). *GDELT: Global data on events, location and tone, 1979–2012* [Conjunto de datos]. The GDELT Project. <https://www.gdeltproject.org>

Organización de las Naciones Unidas para la Alimentación y la Agricultura. (s.f.). *FAO newsroom* [Canal RSS]. Recuperado el 11 de septiembre de 2026 de <https://www.fao.org/newsroom/rss/en>

Organización Mundial de la Salud. (s.f.). *Disease Outbreak News*. <https://www.who.int/emergencies/disease-outbreak-news>

Poultry Site. (s.f.). *The Poultry Site* [Canal RSS]. Recuperado el 11 de septiembre de 2026 de <https://www.thepoultrysite.com/rss/>

Reuters. (s.f.). *Reuters Agency: Health* [Canal RSS]. Recuperado el 11 de septiembre de 2026 de https://reutersagency.com/feed/?best-topics=health&post_type=best

Society for Science. (s.f.). *Science News*. <https://www.sciencenews.org>

The GDELT Project. (2017, 30 de agosto). *GDELT DOC 2.0 API debuts*. <https://blog.gdeltproject.org/gdelt-doc-2-0-api-debuts/>

Software, modelos y datos

Ollama. (s.f.). *Ollama* [Software]. <https://ollama.com>

Oracle. (s.f.). *MySQL* (versión 8) [Software]. <https://www.mysql.com>

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J. y Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. En H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox y R. Garnett (Eds.), *Advances in Neural Information Processing Systems 32*. <https://pytorch.org>

Qwen Team. (2024). *Qwen2.5* (versión 3B) [Modelo de lenguaje de gran tamaño]. Alibaba Cloud. <https://ollama.com/library/qwen2.5>

Ramírez, S. (s.f.). *FastAPI* [Software]. <https://fastapi.tiangolo.com>

SQLite Development Team. (s.f.). *SQLite* [Software]. <https://www.sqlite.org>

You, E. (s.f.). *Vite* [Software]. VoidZero. <https://vitejs.dev>

Norma de citación

American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7.^a ed.). <https://doi.org/10.1037/0000165-000>

A. Último ciclo de minería

Este anexo reproduce el JSON de `POST /cycle` en el Mac (`CYC-20260911T093819Z;max_sources=15;demo_seed=false`). Los campos no se han redondeado ni se ha forzado que sumen entre sí.

Tesis que este ciclo demuestra. Con 15 fuentes `RSS/API` se trajeron 57 ítems y **cero** artículos nuevos: 21 duplicados y 57 fuera de relevancia. Ocho fuentes `scrape` siguieron diferidas. El observatorio estaba vivo (Ollama `qwen2.5:3b`, MySQL al día). El corpus de sala siguió en 26. Ese cero no se arregla con otro clic en sala: se arregla con el snapshot `faee421` y, para sumar después, con `mac/minar-ya.command`.

Tabla 9: Respuesta del ciclo `CYC-20260911T093819Z`.

Campo	Valor	Qué implica
<code>cycle_id</code>	<code>CYC-20260911T093819Z</code>	11 de septiembre de 2026, 09:38 UTC.
<code>sources_checked</code>	15	Tope pedido; aún no son las 118 del catálogo.
<code>scrape_deferred</code>	8	Candidatas <code>HTML</code> ; no se pidió la página.
<code>articles_fetched</code>	57	Ítems que llegaron a desduplicado/relevancia.
<code>articles_new</code>	0	Nada nuevo en sala tras los filtros.
<code>skipped_duplicates</code>	21	Misma URL o huella de texto.
<code>skipped_relevance</code>	57	Fuera de las tres enfermedades o umbral.
<code>images_processed / cnn_samples_new</code>	0 / 0	Sin imágenes nuevas; el dataset visual no creció.
<code>claims / alerts (ciclo)</code>	0 / 0	No hubo ítem nuevo que extraer o alertar.
<code>LLM</code>	Ollama <code>qwen2.5:3b</code>	Disponible; el ciclo no depende de él para contar artículos.
<code>kpis.articles al cierre</code>	26	Sala e MySQL coinciden; no son los ~160 de Windows.
<code>by_format</code>	<code>RSS 24; API 3</code>	Cien por ciento de los documentos con cuerpo de feed.
<code>mining_runs</code>	17	Historial de corridas en este Store.
<code>mysql_lag_seconds</code>	0	MySQL conectado y al día.
<code>max_sources</code>	15	Parámetro del <code>POST</code> ; no obliga a 15 si hay menos <i>due</i> .
<code>project_root</code>	<code>Generador_Excel_Enfermedades</code>	Raíz opcional de demo en el Mac.




Figura 9: Fotografía del ciclo CYC-20260911T093819Z. El cero en *nuevos* es el dato, no un hueco en la gráfica.

A.1. Por qué 15 y no 118

El orquestador (`pipeline/run.py`) construye la cola así:

1. Sincroniza el catálogo (118 filas en este corte).
2. Toma `sources_due(..., methods=("api", "rss"))` y recorta a `max_sources`.
3. Toma hasta 8 fuentes *scrape* vencidas y las deja *diferidas* (anotadas, sin descarga).
4. Un 404 incrementa fallos seguidos y aplica *backoff*: esa fuente deja de estar *due* en el siguiente clic.

En una corrida previa del mismo día solo maduraron 8 feeds. Aquí el tope fue 15 y se revisaron 15: el fetch subió (7 → 57 ítems) y el corpus **no**. Para llegar a ~160 no hace falta otro clic: hace falta el snapshot del commit `faee421` (anexo D) y, para seguir sumando, `mac/minar-ya.command`.

A.2. Errores de fuente observados

Los 404 no se cuentan como «cero desinformación». Se cuentan como salud del catálogo. El ciclo CYC-20260911T093819Z registró cinco HTTP 404 con URL explícita (fichas APA en la sección 14):

Tabla 10: Errores HTTP 404 del ciclo CYC-20260911T093819Z.

Id	Organización	URL consultada
SRC003	FAO Newsroom	https://www.fao.org/newsroom/rss/en
SRC014	ECDC	https://www.ecdc.europa.eu/en/rss.xml
SRC037	Reuters Agency (health)	https://reutersagency.com/feed/?best-topics=health&pos_t_type=best
SRC073	The Poultry Site	https://www.thepoultrysite.com/rss/
SRC075	Food & Agribusiness World	https://www.foodagribusiness.world/poultry/rss

B. Métricas de la CNN

La pestaña CNN y GET `/stats` del 11 de septiembre de 2026 reportan **11 imágenes**, todas etiquetadas OFFICIAL_DOCUMENT. En este workspace de redacción **no** hubo archivo de métricas de prueba (`test_metrics.json` bajo `models/cnn/`). Por eso *no* se publica *accuracy*, *macro-F1* ni una matriz de confusión entrenada: un número inventado sería peor que un hueco.

Lo que sí se puede defender es el **soporte por clase** y la conclusión metodológica: con $n = 11$ y una sola clase poblada, cualquier exactitud cercana a 1,0 sería la línea base de la clase mayoritaria, no un detector de ocho géneros visuales.

Tabla 11: Soporte operacional por clase (*vision_cnn_v1*), laboratorio 11 de septiembre de 2026. No hay hold-out etiquetado: es el recuento de sala.

Clase	Soporte	En sala	Métrica defendible
OFFICIAL_DOCUMENT	11	11	Única clase con masa.
NEWS_SCREENSHOT	0	0	Precisión/recall no definidas.
SOCIAL_MEDIA	0	0	Precisión/recall no definidas.
MEME	0	0	Precisión/recall no definidas.
INFOGRAPHIC	0	0	Precisión/recall no definidas.
ANIMAL_HEALTH_CONTENT	0	0	Precisión/recall no definidas.
PHOTOGRAPH	0	0	Precisión/recall no definidas.
POTENTIALLY_MANIPULATED	0	0	Precisión/recall no definidas.
Total	11	11	8 clases nominales; 1 efectiva.

Tabla 12: Qué se puede y qué no se puede citar de la CNN en este corte.

Afirmación	Veredicto
Hay un cableado de 8 clases y pesos <i>vision_cnn_v1.pt</i> .	Sí: el módulo existe y se reentrena en local.
El dataset de laboratorio está desbalanceado.	Sí: 11/11 en un solo género.
La exactitud de prueba es del x %.	No. Falta <i>test_metrics.json</i> y falta diversidad.
El modelo detecta <i>deepfakes</i> o membretes falsos.	No. Clasifica género visual; no es peritaje.
Un clasificador constante <i>OFFICIAL_DOCUMENT</i> acierta este corte.	Sí: línea base trivial = 1,0. No se ofrece como resultado.
<i>Macro-F1</i> de 8 clases.	No es informativo: siete soportes son cero.

	OD	NS	SM	ME	IN	AH	PH	PM
OD	11	0	0	0	0	0	0	0
NS	0	0	0	0	0	0	0	0
SM	0	0	0	0	0	0	0	0
ME	0	0	0	0	0	0	0	0
IN	0	0	0	0	0	0	0	0
AH	0	0	0	0	0	0	0	0
PH	0	0	0	0	0	0	0	0
PM	0	0	0	0	0	0	0	0

Clase en datos

Clase observada en el corte

Figura 10: No es una matriz de confusión de un hold-out: es el recuento de sala. OD = documento oficial; el resto sigue la tabla 7. El 11 en la diagonal es el argumento.

B.1. Métricas que harían defendible el modelo

Cuando exista un `test_metrics.json` de un conjunto de prueba con las ocho clases pobladas, el anexo debería sustituir las tablas anteriores por, como mínimo:

- n de entrenamiento / validación / prueba, por clase;
- exactitud y *macro-F1* (y *weighted-F1*);
- precisión, recall y *f1* por clase, con `zero_division` explícito;
- matriz 8×8 de un hold-out, no del recuento de sala;
- fecha, semilla y comando `python -m ai_service.vision.train_cnn`.

Hasta entonces, la frase correcta frente a un comité es: *el prototipo está cableado; el corpus visual no permite generalizar*.

C. Catálogo de fuentes

El Store declara **118 fuentes** en el corte del 11 de septiembre de 2026, con método de captura $\approx 100\%$ RSS (el acceso `scrape` está en catálogo pero diferido). Este anexo no fabrica las 118 razones sociales: no hubo un volcado de `GET /sources` en el workspace de redacción. Lo que sí se puede defender es (1) cómo está pensado el catálogo, (2) las fuentes que la sala y los ciclos sí nominaron, y (3) cómo regenerar la lista completa en el equipo local.

C.1. Diseño del catálogo

Tabla 13: Criterios con los que se arma el directorio de fuentes.

Criterio	Aplicación en <i>The NewsBreakers</i>
Temático, no mediático	Entra un feed si cubre las tres enfermedades o el entorno pecuario. No se exige que sea un periódico mexicano.
Inglés de insumo	Agencias, ciencia y GDELT entran en original. La traducción es capa opcional y cacheada.
RSS/API primero	Un canal estable gana a un <i>scraper</i> frágil.
Oficial y no oficial	OMS, ciencia, diario y agregador conviven; el riesgo se anota aparte.
Salud del endpoint	Un 404 no borra la fuente: la marca, aplica <i>backoff</i> y sigue.

C.2. Muestra nominada (sala y ciclos)

Tabla 14: Fuentes que aparecieron con nombre propio en la sala o en logs de ciclo. Muestra de auditoría, no el censo de 118.

Fuente	Método	Estado visto	Papel en el corte
GDELT DOC 2.0	API/RSS	Operativa	Notas de barrenador (p. ej. riesgo 20).
<i>Science News</i>	RSS	Operativa	Influenza aviar (comederos de patio; riesgo 38).
<i>El País</i> (México)	RSS	Operativa	Nota generalista de alto riesgo percibido (62).
Ítem clínico / mono	RSS	Operativa	Tarjeta de riesgo 30 en la misma sala.
<i>The Poultry Site</i>	RSS	404	Catálogo pecuario; feed no servía.
Poultry World	RSS	404	Idem.
OMS DON	RSS	404	Canal oficial; endpoint caído.
Reuters (agencia)	RSS	404	Agencia; no confundir con «silencio epidémico».

La mezcla de la sala en ese corte —dos menciones de barrenador, ocho de influenza aviar, cero de peste porcina clásica— sigue a estas fuentes: el inglés científico empuja la aviar; la PPC aún no tiene masa en los feeds que maduraron.

C.3. Cómo completar las 118 filas

En el equipo donde corre el API (127.0.0.1:8010):

```
curl -s http://127.0.0.1:8010/stats
curl -s http://127.0.0.1:8010/sources
```

El primero refresca la tabla 8. El segundo es el censo que este PDF no inventa. Si existe `models/cnn/test_metrics.json`, sustituye el anexo B. Ningún dato de esos volcados debe pegarse aquí sin fecha: el corte válido es el del archivo, no el de la memoria.

D. Por qué 26 en Mac y cómo igualar ~160

Hasta el commit `faee421` del repo privado, un `git clone` en el Mac arrancaba vacío: GitHub no traía `tnb.db` y un ciclo `rss` corto se quedaba en ~26. No había `LIMIT 26` en el código. El Mac solo veía lo que minaba ahí. El corpus de Windows —Excel, YouTube y el resto, ~160 notas— vivía en otra máquina.

Datos y minero Mac subió esa base al remoto (`faee421`) y dejó un minero que sí añade notas nuevas. Igualar ya no es USB: es `git pull` con el API parado.

Tabla 15: El mismo código, dos memorias. El snapshot en Git cambia el recuento; un ciclo RSS corto no.

Situación	Artículos	Qué es
Windows (origen del snapshot)	~160	Generador Excel, YouTube y el resto del Store.
Mac con clone anterior a <code>faee421</code>	0	El remoto aún no llevaba la base.
Mac tras un ciclo <code>rss</code> corto	~26	Lo que el minero viejo metió; no un <code>LIMIT 26</code> .
Mac tras <code>git pull ≥ faee421</code>	~160	El snapshot ya está en GitHub.
YouTube / redes sin claves	~37 (en el corte)	Vienen en el snapshot; no crecen al minar.

No es un fallo del Mac. El ciclo `CYC-20260911T093819Z` trajo 57 ítems y cero nuevos porque reconsultaba URL ya vistas. Eso quedó corregido en el `git pull`: el minero ya no espera 15–60 min entre fuentes ni machaca las mismas direcciones.

D.1. Paso concreto (igualar 160)

Si `git pull` aborta porque hay cambios locales (`api/main.py`, `pipeline/run.py`, los `.command`), el instalador arranca el código viejo y la sala sigue en ~26. Hay que guardar esos parches, traer `faee421` y reiniciar:

```
cd ~/the-newsbreakers-framework
./mac/detener.command
git stash push -m "parches locales Mac antes de faee421"
git pull origin main
git log -1 --oneline
chmod +x mac/*.command
./mac/Instalar-y-abrir.command
```

`git log -1` debe mostrar `faee421` (o posterior). No hace falta `git stash pop`: el remoto ya trae el minero. Recargar `http://127.0.0.1:5173/#/`. El recuento debe pasar de ~26 a ~160.

Si, tras el fast-forward a `faee421`, `zsh` responde `permission denied` al lanzar un `.command`, el archivo llegó sin bit de ejecución (`minar-ya.command` está en el remoto como `100644`). No hace falta repetir el pull:

```
cd ~/the-newsbreakers-framework
chmod +x mac/*.command
./mac/Instalar-y-abrir.command
```

Si el instalador imprime Artículos en SQLite local: 0 y `curl /stats` responde `Internal Server Error`, el `chmod` ya no es el problema: la base que monta el API está vacía, es otro fichero, o el snapshot se pisó al crear `.env` desde el example. Parar y restaurar el blob de git (~1,3 MB):

```
./mac/detener.command
git checkout HEAD -- data/processed/tnb.db
ls -lh data/processed/tnb.db
./mac/Instalar-y-abrir.command
curl -sS http://127.0.0.1:8010/stats
```

No lanzar `minar-ya` hasta que `/stats` devuelva JSON. El traceback está en `logs/mac-api.log`. En el Mac, el 11 sep 2026 a las 11:09 UTC eso ya ocurrió: `/stats` 200 con 160 artículos. El fichero de 792 KB estaba corrupto (malformed database schema (mining_runs) - invalid rootpage); el blob de git (~1,3 MB) lo sustituyó. Causa probable: `git pull` del `.db` dejando un diario WAL viejo. Antes del próximo pull, parar la API y borrar `tnb.db-wal` y `tnb.db-shm`.

D.2. Seguir sumando (RSS y GDELT)

```
./mac/minar-ya.command
```

Dejar el Mac despierto. Varios ciclos seguidos. YouTube y redes no crecen sin claves de API; esas ~37 notas ya vienen en el snapshot. El botón de sala *Ejecutar ciclo* no sustituye a `minar-ya.command`.

D.3. Lo que dejó `minar-ya` 8/8 (11 sep 2026)

El script imprimió 337 «artículos» porque suma los «nuevos» de cada ciclo al 160 inicial. El Store real (SQLite y MySQL) quedó en 203. La tabla `articles` del Mac tenía 337 filas. Un listado por título (no borra) separó tres cubetas: título nombra la enfermedad; cuerpo sucio (Figlia, Powerball, grano, Trump rancher: el scrape metió nav de CFIA/WOAH en la nota); fuera (Houthis, Oasis, mascotas, Science Daily).

Tabla 16: Recuentos tras los ocho ciclos, frente al snapshot.

Indicador	Valor	Lectura
Snapshot faee421 (<code>/stats</code> 11:09 UTC)	160	Base Windows restaurada.
Tras ciclo 1 (SQLite)	118	El snapshot no se conservó como piso.
Nuevos ciclo 1 / ciclo 2	92 / 76	Ciclo 2: 2 claims, 74 alertas.
Store SQLite/MySQL al 8/8	203	No es el 337 del log.
Filas <code>articles</code>	337	Incluye ruido de Science Daily y SRC029.
Fuera de mandato (título)	126	Houthis, Oasis, mascotas, One Health.

Una pieza fuera de las tres enfermedades es un fallo del filtro, no un éxito de minería. El parche en este informe (`patches/the-newsbreakers-framework/`) exige nombrar la enfermedad **en el título**; el LLM local no admite; sin claim anclado no hay alerta. Instalar:

```
python3 patches/the-newsbreakers-framework/scripts/install_gate.py \
  --root "$HOME/the-newsbreakers-framework"
python3 ~/the-newsbreakers-framework/scripts/flag_offtopic.py
```

Apagar SRC-SCIENCE-DAILY-VET y SRC029. No lanzar otro `minar-ya` hasta esos ganchos.

D.4. Plan B y matices

- Si el pull no trae `data/processed/tnb.db`, copiar el archivo desde Windows (API parada, USB o AirDrop) y, si hace falta, `storage/images`.

- MySQL en Docker, si está atrasado o apagado, no sustituye al SQLite del snapshot. La sala lee el Store que el API tenga montado.
- Subir `max_sources` no iguala 160 si la base local sigue siendo la de ~26.

Fin del informe técnico v. 1.5. Anexos con el ciclo `CYC-20260911T093819Z` (26 en sala *antes* del snapshot), el procedimiento `faee421 / minar-ya.command` y el gate por título tras el 8/8. Donde faltó un JSON de visión, se declaró la falta.