



The NewsBreakers

Observatorio de desinformación zoonosanitaria. Informe técnico del framework, v. 2.2. México, 12 de septiembre de 2026. Sustituye al v. 2.1.

Vigilancia de tres enfermedades pecuarias: gusano barrenador del ganado (*Cochliomyia hominivorax*), influenza aviar de alta patogenicidad y peste porcina clásica. El operador trabaja en una sala: ve notas, riesgo, alertas, mapa, gráficas, grafo y visión. El sistema no decide la verdad. Extrae afirmaciones, cruza fichas oficiales, calcula un riesgo y deja la última palabra al analista (Validar, Descartar, Modificar).

Cómo leer este documento. Las secciones van en el orden de uso: abrir la app, leer la sala, abrir una ficha, revisar, minar, y luego mapa, gráficas y grafo. No se etiquetan noticias como fake o real.

1. Qué es y qué no es

Paso	Lo que sí	Lo que no
Fetch	RSS, GDELT y API del catálogo. Título, fecha, enlace, cuerpo si viene.	No entra al HTML de redacciones que exigen rastreador a medida (scrape diferido).
Deduplicado	Evita contar dos veces la misma URL o huella de texto.	No fusiona versiones periodísticas distintas.
Relevancia	Tira lo que no nombra las tres enfermedades.	No es un fact-checker general.
Afirmaciones	Parte el texto y lo cruza con fichas WOA, USDA, FAO, SENASICA.	No atribuye intención ni autoría legal.
Riesgo	Suma seis señales (motor weighted_v3). Ordena la cola.	No es un % de que la nota sea falsa.
CNN	Sugiere el tipo de imagen (acta, meme, foto...).	No certifica si una foto está manipulada.
HITL	Validar, Descartar o Modificar en la ficha y en Revisión.	No sustituye el dictamen sanitario oficial.

2. Cómo se abre hoy

El producto es una app de escritorio. No se trabaja en una pestaña de Chrome. La sala, la ficha, el mapa, las gráficas y el grafo son los mismos en cualquier PC. Cambia el archivo de instalación: el de macOS, el de Windows o el de Linux, según la máquina. Doble clic. El API local queda en 127.0.0.1:8010 y sirve la UI. Los datos viven en la carpeta de la aplicación del usuario; no se van con el instalador. Los enlaces externos salen al navegador del sistema. Tras un cambio de interfaz hay que cerrar la app del todo y volver a abrir. Código: <https://github.com/JAVGP444/the-newsbreakers-framework>

Uso	Cómo	Puertos
App instalada	Instalador o binario del sistema en uso. Doble clic.	API :8010; la UI la sirve el API
Desarrollo	Clone del repo y script de arranque.	UI :5173 · API :8010

SQLite (data/processed/tnb.db) abre la sala. MySQL en Docker es almacén opcional. Sin Docker el observatorio funciona. Postgres, Mongo y Redis del compose no hacen falta para la UI.

3. Por qué esas tres enfermedades

Enfermedad	Por qué entra	Qué se vigila en medios
Gusano barrenador (C. hominivorax)	Reemergencia México–Centroamérica; pánico en caza y traspato.	Avisos a cazadores, heridas, rumores de mosca estéril.
Influenza aviar (HPAI)	Circulación global; el lenguaje técnico se deforma en redes.	Granjas, sacrificio, «gripe del pollo» como pánico alimentario.
Peste porcina clásica	Declaración obligatoria; se confunde con africana en titulares.	Cierres de granja, contrabando, vacunas «ocultas».

Hay vocabulario estable en español e inglés, daño mediático concreto y fuentes abiertas. COVID humano, dengue o vacunas infantiles no entran: diluirían el filtro y la cola humana.

4. Países e idiomas

El centro operativo es México: sala en español, autoridad pecuaria nacional, corredor del barrenador. El mapa no es un GIS oficial: sitúa dónde el texto dice que ocurre algo. El inglés entra por GDELT, ciencia y cables. El conmutador «Traducir al español» es capa de lectura: el artículo se guarda como llegó; la traducción se cachea. El texto que ya está en español no se reescribe. Por defecto la traducción usa Google gtx; Ollama solo si TNB_TRANSLATE_OLLAMA=1.

5. Medios y catálogo

Tipo	Acceso	Papel
GDELT DOC 2.0	API	Radar. Mucho volumen, poco cuerpo. El lede de GDELT (fecha compacta + sopa de palabras) no se muestra en sala ni en ficha.
Prensa pecuaria y científica	RSS	Vocabulario técnico; a veces el rumor nace de un titular correcto mal leído.
Prensa general	RSS	Encuadre nacional.
Organismos (WOAH, FAO, OMS, USDA, SENASICA)	RSS / ficha	Ancla de evidencia. Un 404 se registra y el ciclo sigue.

YouTube / redes	Catálogo; ingestión desigual	Donde circula la imagen recortada.
HTML scrape	Diferido	No infla el contador. Mantener selectores CSS es otro producto.

6. Cómo está armado el framework

Monorepo local. La sala no habla con SQLite: pasa por FastAPI en 127.0.0.1:8010. Si se apaga el API, la ventana puede pintar el cascarón y decir que no hay servidor. Los datos no se borran al cerrar.

Ventana Nativa. Misma UI compilada (frontend/dist) en cualquier PC.	API /articles /stats /cycle /alerts /geo /graph /charts /translate /cnn	Pipeline pipeline/run.py: catálogo vencido, fetch, dedup, relevancia, claims, NLI, riesgo, imagen.
Modelos vision_cnn_v1.pt · NLI léxico vs fichas oficiales · riesgo weighted_v3.	Datos tnb.db · imágenes en storage/ · caché de traducción.	Empaque packaging/build.py arma el paquete nativo de la máquina donde se corre.

Ruta	Función
ingestion/	Fetch RSS/API/GDELT, normalización, deduplicado.
pipeline/run.py	Orquesta un ciclo.
api/	Contrato HTTP, HITL, estáticos de la UI.
frontend/	Tablero Vite 5. Sala, ficha, mapa, gráficas, grafo, CNN.
ai-service/	Riesgo, NLI, OCR, CNN, LLM opcional.
database/	Store SQLite, filtros, thumbs.
config/	Rutas de datos, umbrales, intervalo de minería.
desktop/	Arranque: API local + ventana.
packaging/	Paquete nativo según el sistema (build.py).
models/cnn/	Pesos .pt y dataset visual.

7. El ciclo de minería

Orden real: catálogo → fuentes vencidas rss/api → fetch → dedup URL+texto → relevancia zoosanitaria → afirmaciones y entidades → NLI contra fichas oficiales → riesgo y alerta → imagen y CNN. El scrape no está en esa fila: se marca diferido.

Pulsar «Ejecutar ciclo» no dispara todo el catálogo. Solo las fuentes debidas. Un 404 de un feed no tumba el ciclo. Cero artículos nuevos con 57 ítems traídos es diseño: duplicados y fuera de las tres enfermedades. Para crecer el corpus: «Ejecutar ciclo» en la app o el script de minería del repo.

8. Riesgo (weighted_v3) y veredictos

No hay un único «score de fake». El recuadro 0–100 es la suma ponderada de seis señales. Un 20 no afirma que el hecho sea falso: afirma poco peso de alarma. Un 62 pide ojos humanos.

Señal	Peso	Qué mide
-------	------	----------

Discrepancia con evidencia	0.28	NLI vs fichas oficiales. Unknown con poco overlap no es respaldado.
Fiabilidad de la fuente	0.22	Autoridad A (WOAH/SENASICA) a E (redes). GDELT/prensa = C.
Imagen reusada	0.18	pHash de la foto en otras notas.
Gravedad de la afirmación	0.18	Brote, cifra, «oculta»; un título solo pesa poco.
Narrativa en crecimiento	0.08	Pico del mismo relato en el periodo.
Anomalía visual	0.06	Clase CNN o falta de imagen.

Veredictos de tarjeta: Respaldado, Insuficiente, Posiblemente engañoso, Contradicho, Revisión humana. Insuficiente: no hay base aún para un juicio fuerte. NLI de una afirmación: Respaldado / Contradicho / Sin verificar (Unknown). Unknown es el valor por defecto cuando el cruce léxico no alcanza (hace falta overlap mínimo con la ficha).

9. Sala

Las tarjetas ya no apilan estados ni el cuerpo basura de GDELT. Cada una muestra: miniatura, tipo de fuente, veredicto, riesgo, título en dos líneas, pie con host · fecha de publicación · Original. La fecha es la de la nota (published_at), no la de minado. Las fechas compactas GDELT (20260912T014500Z) se leen como 12 sep 2026. Si no hay publicación: «Sin fecha de publicación». Orden de la lista: publicación primero, para que una nota vieja recién minada no salte al tope.

La tira Respaldado / Insuficiente / ... está en Sala, no dentro de cada ficha. «Qué es cada uno» se abre ahí. Sin «Leer más» ni extracto de keywords H5N1/SENASICA/WOAH pegadas al título. Navegación: Sala · Revisión · Mapa · Gráficas · Grafo · CNN · Fuentes. Los filtros de la sala (enfermedad, país, fechas, origen) se arrastran a mapa, gráficas y grafo por la misma querystring.

10. Ficha (clic en una tarjeta)

Layout de nota + veredicto, no una planilla de fórmulas.

Columna	Qué se ve
Izquierda: la nota	Foto, fuente, fecha, cuerpo limpio (o «esta nota no trajo cuerpo»), enlace a la original, El caso (enfermedad, animal, país) y línea de tiempo si hay fechas.
Derecha: la lectura	Tipo, veredicto, riesgo N/100, una frase (p. ej. «Relevante, pero sin evidencia suficiente»), Validar / Descartar / Modificar, afirmaciones con postura, chips WOA / USDA / FAO.
Plegado	«Cómo se calculó el riesgo» (seis barras y motivos). «Cruce con fichas oficiales» al abrir una afirmación. La CNN de la imagen, en galería, bajo «Tipo de imagen».

Los enlaces «Abrir noticia original» y las fichas oficiales salen al navegador del sistema.

11. Revisión humana

Pestaña Revisión: cola pending_review. En la ficha, los mismos tres botones. Validar, Descartar o Modificar (motivo obligatorio). El veredicto queda en el artículo. La revisión no pide token de API aparte: POST /articles/{id}/review.

12. Mapa de menciones

Pestaña Mapa (/mapa). GET /geo. Leaflet: un círculo por país. El radio crece con el recuento, no con la gravedad. Clic en un círculo o en la lista del costado abre la sala filtrada por ese país. Si el texto no trae país, va a la línea «Sin ubicar». No es el mapa de focos de SENASICA ni de WOA: sitúa dónde el artículo dice que ocurre algo. En la ficha hay un mapa chico si hay coordenadas. Los filtros de la sala se aplican aquí.

13. Gráficas

Pestaña Gráficas (/graficas). GET /charts. Recharts. Tres recuadros; cada uno trae «Cómo leerlo». Clic en una barra o en un color abre esas notas en la sala. Vacío: aún no hay minería, o el filtro no deja nada.

Gráfico	Qué cuenta
¿De qué enfermedades hablan?	Barras horizontales. Una nota puede nombrar más de una. Número y % sobre el recorte.
¿De dónde sale el contenido?	Barras: oficial (SENASICA, OMSA, CDC...), científico, redes/YouTube, prensa.
¿Qué concluyó el análisis?	Pastel: respaldado, contradicho, insuficiente, revisión humana.

Si casi todo cae en una semana y esa semana coincide con un ciclo de minado, el recuadro avisa: suele ser el día en que se guardó, no siempre el de publicación.

14. Grafo de narrativas

Pestaña Grafo (/grafo). GET /graph. vis-network. Nodos: fuente (azul), enfermedad (verde), narrativa (amarillo), artículo. El tamaño sigue el recuento. Clic en fuente o enfermedad filtra la sala. Clic en un artículo abre la ficha. Leyenda al pie; si hay recorte: «n de N artículos». Vacío: «No hay co-ocurrencias con este filtro.» Tope de muestra 10–80 (por defecto 40). Sirve para ver si varias notas empujan el mismo relato; no es un grafo de contactos epidemiológicos.

15. CNN y fuentes

CNN (/cnn). Lab visual. Ocho clases: documento oficial, captura de noticia, red social, meme, infografía, contenido pecuario, fotografía, posible manipulación. Propone el tipo de imagen; no cierra el expediente.

Fuentes (/fuentes). Salud del catálogo: método de captura, última visita, fallos, estado. Un feed 404 se ve aquí; no se interpreta como «cero desinformación».

16. Visión

La CNN no lee el artículo. Mira la imagen y propone un género visual. El mismo rumor cambia de peso si viaja como acta, pantallazo, meme o foto de un animal. Entrenar es local: python -m ai_service.vision.train_cnn. No hay «la IA se actualiza sola». Un dataset sesgado (p. ej. solo membertes) no autoriza a citar accuracy. POTENTIALLY_MANIPULATED es señal débil, no peritaje.

17. Parámetros de operación

Parámetro	Criterio
-----------	----------

Alerta	Umbral de laboratorio ~55/100. Por debajo existe el ítem; no entra a la cola roja.
Fuentes por ciclo	Solo vencidas rss/api. El tope (p. ej. 40) no son 118 descargas.
Scrape HTML	Anotado, no descargado.
Intervalo	Por defecto 30 min (TNB_MINE_INTERVAL_MINUTES).
Sala	Paginada. Orden por fecha de publicación.
Grafo	Muestra 10–80 artículos (por defecto 40).

18. Por qué se hizo así

- Local primero. El índice no depende de un SaaS para abrir la sala. SQLite en el portátil; MySQL si hay Docker.
- App, no pestaña. Un mismo escritorio en cualquier PC. Enlaces oficiales sí salen al navegador.
- RSS/API antes que scrape. Cincuenta extractores CSS son un medio, no un observatorio.
- Relevancia estricta. Mejor pocas notas de las tres enfermedades que cientos de «salud» genérica.
- Humano al final. Seis señales y una cola. Ni un modelo pequeño ni una CNN de pocas fotos cierran el caso.
- Traducción como capa. No se pisa el original.
- Vista, no GIS. Mapa, barras y grafo llevan a la sala. No sustituyen el mapa oficial de focos.

19. Límites

- El catálogo no es N descargas por clic. Solo las vencidas rss/api.
- Feeds 404 son error de fuente, no «cero desinformación».
- GDELT a menudo no trae cuerpo: la ficha lo dice y manda al original.
- El overlap NLI es léxico. Cuatro palabras compartidas con WOAHA no respaldan.
- Sin API local no hay sala.
- El mapa no es incidencia epidemiológica. El grafo no es red de contactos.
- La CNN subalimentada no es detector de deepfakes.
- Los recuentos de un ciclo de laboratorio no se citan como incidencia epidemiológica.

20. Instalar y construir

Se baja el instalador del sistema que se usa. Python 3.12, Node LTS y Git bastan para armarla en esa máquina.

```
git clone https://github.com/JAVGP444/the-newsbreakers-framework.git
cd the-newsbreakers-framework
python -m venv .venv
python -m pip install -U pip
python -m pip install -r requirements.txt
cd frontend && npm install && npm run build && cd ..
python packaging/build.py
```

Ese comando deja el paquete nativo en dist/. El script de arranque del repo sirve para desarrollo (UI :5173 · API :8010) sin pasar por el instalador.

21. Comprobar

```
pytest tests -q
curl -s http://127.0.0.1:8010/health
```

```
curl -s http://127.0.0.1:8010/stats
```

22. Cierre

The NewsBreakers es un marco para no perder tres enfermedades pecuarias en el ruido de los feeds. Se abre, se lee como nota (sala y ficha), se mira en mapa, gráficas y grafo, se contrasta con fichas oficiales y se cierra con un humano. La prevención, aquí, no es un modelo que apaga rumores. Es llegar a la nota con el original intacto.

Cómo citar: The NewsBreakers. (2026). Observatorio de desinformación zoonosanitaria: arquitectura, método y uso (Informe técnico, v. 2.2) [Documento de trabajo]. México.

Referencias (selección)

- American Psychological Association. (2020). Publication manual of the American Psychological Association (7.a ed.).
- Leetaru, K. y Schrodtt, P. A. (2013). GDELT: Global data on events, location and tone [Conjunto de datos]. <https://www.gdeltproject.org>
- Organización Mundial de Sanidad Animal. (s. f.). WOA. <https://www.woah.org>
- Paszke, A. et al. (2019). PyTorch: An imperative style, high-performance deep learning library.
- Ramírez, S. (s. f.). FastAPI. <https://fastapi.tiangolo.com>
- SQLite Development Team. (s. f.). SQLite. <https://www.sqlite.org>
- The GDELT Project. (2017, 30 de agosto). GDELT DOC 2.0 API debuts.
- You, E. (s. f.). Vite. <https://vitejs.dev>